

Estrategias de Trading Avanzadas Basadas en Deep Learning



ITESO

**Universidad Jesuita
de Guadalajara**

Autor: Santiago Ortiz García y Jesús Andrés García-Casarrubios González

Fecha: Octubre 2025

ÍNDICE

Portada	1
Resumen General de la Estrategia	4
Objetivos del Proyecto	4
Conceptos Clave.....	4
Requisitos Técnicos y de Datos	5
Ingeniería de Características	5
Rate of Change (ROC)	5
Relative Strength Index (RSI)	6
Williams %R	6
Kaufman Adaptive Moving Average (KAMA)	6
Awesome Oscillator (AO)	6
Chaikin Money Flow (CMF)	6
Choppiness Index	6
Volatility Ratio (VR)	7
Bollinger Bands	7
Coeficiente de Variación (CDV)	7
On Balance Volume (OBV)	7
Ease of Movement (EOM)	7
Force Index (FI)	8
Volume Weighted Average Price (VWAP)	8
Keltner Channel.....	8
Chande Momentum Oscillator (CMO).....	8
Money Flow Index (MFI)	8
Accumulation/Distribution Index (ADI)	8

Ulcer Index (UI)	9
Regime Clustering (K-Means).....	9
Variable Objetivo	9
Diseño de Modelos	10
Seguimiento Experimental con MLFlow	10
Monitoreo de Drift de Datos	10
Metodología de Backtesting	11
Resultados y Análisis de Desempeño	11
Conclusiones	17

Estrategias de Trading Avanzadas Basadas en Deep Learning

1. Resumen General de la Estrategia

El proyecto desarrolla un enfoque de trading cuantitativo basado en deep learning, cuyo objetivo principal es generar señales de compra, venta o mantenimiento ("long", "short", "hold") a partir de datos históricos de precios e indicadores financieros de volumen, volatilidad y momentum.

La estrategia combina ingeniería de características avanzadas, arquitecturas profundas de redes neuronales (MLP, CNN de manera secuencial) y un sistema robusto de seguimiento experimental con MLFlow, asegurando trazabilidad, reproducibilidad y evaluación integral del rendimiento.

Asimismo, se incorporan herramientas para monitorear el drift de datos, una problemática común en entornos financieros donde las condiciones del mercado cambian a lo largo del tiempo, y un sistema de backtesting realista, que considera costos de transacción, tasas de préstamo y reglas de gestión de posiciones.

2. Objetivos del Proyecto

Desarrollar y procesar características derivadas de series de tiempo, utilizando indicadores técnicos de momentum, volatilidad y volumen en múltiples horizontes temporales.

Diseñar, entrenar y comparar diferentes arquitecturas de deep learning como son MLP y CNN.

Implementar un flujo de trabajo reproducible con MLFlow para registrar parámetros, métricas y versiones de modelos.

Detectar y analizar drift de datos entre los conjuntos de entrenamiento, validación y prueba.

Integrar predicciones del modelo en un sistema de backtesting con costos de trading realistas, aplicando métricas financieras de rendimiento.

Generar código documentado, escalable y con potencial de implementación en entornos de producción.

3. Conceptos Clave

Ingeniería de Características: Transformar precios históricos en señales predictivas mediante indicadores técnicos de momentum, volatilidad y volumen.

Arquitecturas de Series Temporales: Uso de MLP para patrones estáticos, CNN para capturar estructuras locales en secuencias y redes recurrentes para dependencias a largo plazo.

Estandarización de los datos: para el uso eficiente de los modelos se necesita estandarizar los datos para que las diferencias que le marquen no sean tan grandes y pueda predecir de una mejor manera.

Desbalance de Clases: El mercado suele mostrar más periodos “hold” que señales de compra o venta. Se aplican pesos de clase o ajustes de umbrales para equilibrar el aprendizaje y evitar sesgos.

Drift de Datos: Cambios en la distribución de las características a lo largo del tiempo pueden deteriorar el desempeño del modelo. Se monitorea mediante pruebas estadísticas (KS-test).

Versionamiento de Modelos: MLFlow permite registrar parámetros, métricas y artefactos de cada experimento, facilitando comparaciones objetivas entre arquitecturas y versiones.

4. Requisitos Técnicos y de Datos

Datos históricos: 15 años de precios diarios del activo seleccionado.

Calidad de datos: Tratamiento de valores faltantes y validación de integridad temporal.

División temporal: 60% entrenamiento, 20% prueba y 20% validación, respetando el orden cronológico para evitar “look-ahead bias”.

Frecuencia: Dado el uso de datos diarios, se compensa la baja frecuencia con un manejo cuidadoso del desbalance de clases.

5. Ingeniería de Características

Se generan al menos 20 variables predictoras, incluyendo:

Indicadores de momentum: RSI, MACD, Tasa de Cambio, Momentum simple.

Indicadores de volatilidad: ATR, bandas de Bollinger, desviación estándar móvil.

Indicadores de volumen: Volumen promedio móvil, OBV, proporciones de volumen.

Las variables se normalizan mediante escalamiento estándar o min-max, según la naturaleza del indicador, para garantizar estabilidad numérica durante el entrenamiento.

Ahora se explicará los índices financieros que se usaron y una ligera justificación de estos.

1. Rate of Change (ROC)

El ROC mide la tasa de variación porcentual del precio actual respecto al de w periodos atrás. Se incluye porque detecta la aceleración del precio y permite identificar el inicio de movimientos tendenciales. Su sensibilidad lo convierte en una herramienta útil para capturar cambios de impulso en etapas tempranas del movimiento del mercado.

2. Relative Strength Index (RSI)

El RSI cuantifica la fuerza relativa de los movimientos alcistas y bajistas en una escala de 0 a 100. Su incorporación busca identificar condiciones de sobrecompra y sobreventa, permitiendo anticipar reversiones de corto plazo. Este indicador complementa al ROC al añadir una perspectiva contraria, útil para detectar agotamientos de tendencia.

3. Williams %R

Este indicador mide la posición del precio de cierre en relación con el rango alto-bajo de los últimos w periodos. Se seleccionó por su rapidez de respuesta respecto al RSI y por su capacidad para detectar reversiones de corto plazo. Su sensibilidad contribuye a una identificación más oportuna de cambios de dirección en el mercado.

4. Kaufman Adaptive Moving Average (KAMA)

El KAMA ajusta su suavizado en función de la volatilidad. Se utiliza para distinguir entre periodos de consolidación y de tendencia, adaptándose dinámicamente al ruido del mercado. Esto reduce señales falsas y mejora la sincronización de las entradas en contextos tendenciales.

5. Awesome Oscillator (AO)

El AO compara medias móviles de corto y largo plazo para evaluar cambios en el momentum. Se eligió por su capacidad para detectar transiciones entre fases de impulso y corrección, proporcionando información sobre la aceleración del precio de manera independiente al nivel absoluto de cotización.

6. Chaikin Money Flow (CMF)

El CMF combina información de precio y volumen para estimar el flujo de dinero hacia o desde un activo. Este indicador introduce una perspectiva institucional al sistema, permitiendo detectar fases de acumulación (entrada de capital) o distribución (salida de capital). Su uso fortalece la validez de señales tendenciales respaldadas por volumen.

7. Choppiness Index

El índice de choppiness evalúa el grado de direccionalidad del mercado. Se incluye para diferenciar entre fases laterales y fases de tendencia. Esta distinción es esencial, ya que muchos indicadores técnicos producen señales falsas durante periodos sin dirección definida.

8. Volatility Ratio (VR)

El VR mide la relación entre la volatilidad de corto y largo plazo. Se incorpora porque permite anticipar rupturas de rango o transiciones de fases tranquilas a volátiles.

El indicador otorga al modelo una capacidad anticipatoria frente a cambios estructurales en la dinámica del mercado.

9. Bollinger Bands

Las Bandas de Bollinger representan intervalos de confianza estadísticos alrededor de la media móvil del precio.

Su inclusión permite detectar condiciones de sobrecompra o sobreventa relativas y evaluar la dispersión estadística del precio.

Es un componente clave para estrategias de reversión a la media y para el control de riesgo en contextos extremos.

10. Coeficiente de Variación (CDV)

El coeficiente de variación evalúa la relación entre rendimiento y riesgo (desviación estándar). Se seleccionó por su capacidad de medir la estabilidad del rendimiento. Un valor alto implica eficiencia del movimiento del precio, mientras que un valor bajo indica incertidumbre o sobreextensión.

11. On Balance Volume (OBV)

El OBV acumula el volumen en función de la dirección del precio. Su principal utilidad radica en la detección de divergencias entre precio y volumen, las cuales suelen anticipar cambios de tendencia.

Este indicador refuerza la validación de movimientos respaldados por flujo real de capital.

12. Ease of Movement (EOM)

El EOM mide la relación entre variaciones de precio y volumen. Se utiliza para evaluar la facilidad con la que el precio se desplaza con cierto nivel de volumen,

proporcionando información sobre la eficiencia del flujo de capital. Ayuda a confirmar si los movimientos del mercado se producen con soporte suficiente.

13. Force Index (FI)

El FI combina precio y volumen para medir la fuerza detrás de los movimientos del mercado. Este indicador detecta la potencia del impulso, identificando movimientos con volumen significativo. Se integra para ofrecer una medida directa de la energía del mercado.

14. Volume Weighted Average Price (VWAP)

El VWAP representa el precio promedio ponderado por volumen y se usa como referencia institucional.

Su valor sirve para determinar si un activo cotiza por encima o por debajo de su precio de valor justo. El indicador aporta una referencia de precio utilizada por grandes participantes del mercado, mejorando la interpretación del valor relativo.

15. Keltner Channel

El canal de Keltner utiliza el Average True Range (ATR) para construir un rango de precios dinámico. Se seleccionó por su robustez ante valores atípicos y su capacidad para identificar rupturas sostenidas de volatilidad. Complementa a las Bandas de Bollinger al emplear una medida más estable de la dispersión.

16. Chande Momentum Oscillator (CMO)

El CMO mide la intensidad del momentum mediante la comparación entre días alcistas y bajistas. Su inclusión permite detectar con mayor sensibilidad los cambios en el impulso direccional de corto plazo, mejorando la respuesta del sistema ante microtendencias.

17. Money Flow Index (MFI)

El MFI es un RSI ponderado por volumen, y se integra para evaluar el flujo real de dinero. Evita falsas señales del RSI convencional al incorporar la magnitud de las transacciones. Se usa ampliamente en análisis cuantitativo como medida de presión compradora o vendedora efectiva.

18. Accumulation/Distribution Index (ADI)

El ADI mide la acumulación o distribución de capital basándose en el rango de precios y el volumen. Su principal ventaja radica en la detección de divergencias persistentes entre precio y volumen, lo que ofrece señales de cambio de tendencia con antelación.

19. Ulcer Index (UI)

El Ulcer Index mide la profundidad y duración de las caídas desde máximos recientes. Se seleccionó por su capacidad para evaluar el riesgo percibido y la estabilidad del activo, incorporando una dimensión psicológica al modelo. Ayuda a evitar señales falsas en entornos de estrés financiero prolongado.

20. Regime Clustering (K-Means)

El último indicador no es técnico tradicional, sino un modelo de aprendizaje no supervisado basado en K-Means.

Clasifica periodos del mercado en tres regímenes principales: crisis, alta tendencia (momentum) y reversión a la media.

Su inclusión permite que el sistema se adapte dinámicamente al contexto de mercado, ajustando la interpretación de las señales según el entorno detectado.

El conjunto de indicadores se diseñó para cubrir de forma integral las distintas dimensiones del comportamiento de los precios.

La selección busca equilibrio entre indicadores tendenciales, contrarios, volumétricos y contextuales, reduciendo la probabilidad de sobreajuste y mejorando la generalización del modelo.

Esta arquitectura de indicadores permite que los modelos de Deep Learning (MLP y CNN) aprendan patrones robustos y representativos de diversas condiciones de mercado, mejorando su capacidad predictiva y reduciendo la dependencia de un solo tipo de señal técnica.

6. Variable Objetivo

La variable objetivo está definida con tres posibles etiquetas:

1: Señal de compra (long)

0: Mantener posición (hold)

-1: Señal de venta (short)

El umbral de asignación se establece en función del retorno futuro esperado o de un diferencial porcentual respecto al precio actual. Dado que las señales de “hold” suelen dominar el conjunto de datos, se aplica ponderación de clases durante el entrenamiento para penalizar los errores en las clases minoritarias y mejorar la sensibilidad del modelo ante cambios de tendencia.

Esta variable de señales de compraventa se calculó usando los índices previamente mencionados cada uno arrojando una señal de compraventa o hold, y de la forma que se decidió que si tenía que comprar es que al menos el 65%

7. Diseño de Modelos

MLP (Perceptrón Multicapa): Estructura base de referencia. Incluye múltiples capas densas con activaciones ReLU, dropout para regularización y optimización con Adam. Ideal para combinar características numéricas sin dependencia temporal.

CNN (Red Convolucional): Captura patrones temporales locales en ventanas de tiempo deslizantes. Utiliza kernels de tamaño variable y pooling adaptativo para reducir dimensionalidad sin perder información relevante.

Modelo Secuencial (RNN / LSTM): Diseñado para procesar secuencias completas de precios y aprender dependencias temporales prolongadas. Cada celda recurrente maneja estados ocultos que permiten retener información de eventos pasados.

8. Seguimiento Experimental con MLFlow

Cada experimento se registra con:

Parámetros de entrenamiento (arquitectura, tasa de aprendizaje, batch size, épocas, etc.)

Métricas (accuracy, F1-score, rendimiento en test, pérdida)

Artefactos (modelos entrenados, curvas de aprendizaje, reportes de clasificación)

La comparación entre modelos (MLP vs CNN) se realiza mediante una tabla de métricas consolidadas, identificando el modelo con mejor desempeño global y consistencia en el set de prueba.

Después de haber comparado los modelos de MLP y CNN se comparan entre ellos mismos para ver cuál fue el modelo con mayor accuracy y uno con una accuracy alrededor del 60% esto con la meta de verificar si necesariamente una mayor accuracy da mejores resultados debido a como se comentó que la mayoría de los casos son 0 por lo cual una mayor accuracy puede que represente puras señales de hold por lo cual se quiere verificar con índices financieros ver cuál fue el mejor.

9. Monitoreo de Drift de Datos

El monitoreo de drift se basa en pruebas estadísticas:

Kolmogorov-Smirnov (KS-test) para variables continuas.

Chi-cuadrado para variables categóricas (si aplica).

Se construye un panel con visualizaciones de distribuciones por conjunto (train, test, val) y una tabla resumen con p-valores. Se resaltan las características que presentan drift significativo ($p < 0.05$).

Las causas más comunes incluyen cambios de régimen de mercado, shocks macroeconómicos o variaciones abruptas en la volatilidad.

10. Metodología de Backtesting

Generación de señales: Basada en las predicciones del modelo final.

Reglas de gestión de posiciones:

Stop Loss (SL) y Take Profit (TP) configurables.

Tamaño de posición (N) definido en función del capital disponible.

Costos y supuestos de mercado:

Comisión: 0.125% por transacción

Tasa de préstamo (short): 0.25% anual

Enfoque

walk-forward:

El modelo se entrena y evalúa de forma secuencial sobre ventanas móviles, simulando condiciones de operación reales sin fuga de información.

Lo que se realizó también al final del backtesting fue calcular métricas financieras como pudieron ser sharpe, calmar y winrate para verificar el trading realizado si es que hubo ganancias o no, al igual que se hizo lo mismo con los datos reales es para verificar cual crea un mejor modelo con menores pérdidas o algunas ganancias.

11. Resultados y Análisis de Desempeño

Ahora se hablará de los modelos, primero que nada, el modelo que mejor se ajustó tanto en términos como son métricas de accuracy y f1_score y en el desempeño del modelo fue el de MLP, esto debido que a diferencia del modelo CNN este MLP, por cosas como al manejarse de manera no lineal entre indicadores de volatilidad, tendencia y volumen logro adaptarse mejor a los cambios. Y este modelo se ajusta mejor a la escala temporal y estructura de los datos.

Drift de los datos.

Los 5 parámetros con más drift fueron On balance volumen, Keltner Channel tanto la banda media y superior, Kaufman Adaptive Moving Average y la banda media de bollinger.

Esto que nos quiere decir es que hubo un gran cambio estructural de Oracle en estos tiempos es decir el crecimiento explosivo que tuvo Oracle en 2024/2025 hizo que mostrara como la media de tanto la varianza y la media. Y esto se refleja en los índices ya que la mayoría muestran crecimientos de más del 100% en las medias diciendo que con el crecimiento de orcl estas generaron un mayor drift. Aquí se presenta la tabla de estos datos.

```
- **Ind_obv** - train->test: Δμ=1.497 (205.81%), Var×=0.189; train->val: Δμ=2.139 (294.06%), Var×=0.517
- **Ind_kc_h** - train->test: Δμ=0.6584 (115.29%), Var×=3.06; train->val: Δμ=2.196 (384.58%), Var×=47
- **Ind_kama** - train->test: Δμ=0.6436 (112.67%), Var×=2.98; train->val: Δμ=2.212 (387.19%), Var×=41.6
- **Ind_kc_m** - train->test: Δμ=0.6677 (115.83%), Var×=2.97; train->val: Δμ=2.214 (384.04%), Var×=40
- **Ind_boll_m** - train->test: Δμ=0.6669 (115.85%), Var×=2.99; train->val: Δμ=2.211 (384.02%), Var×=40.2
```

A continuación, se presentarán la gráfica de los 5 parámetros mencionados.

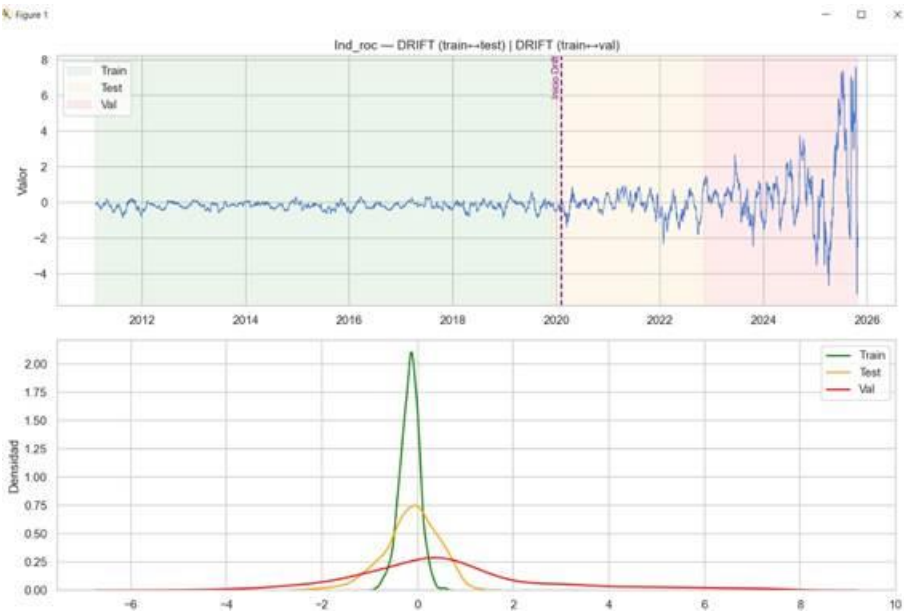


Figure 1




Figure 1

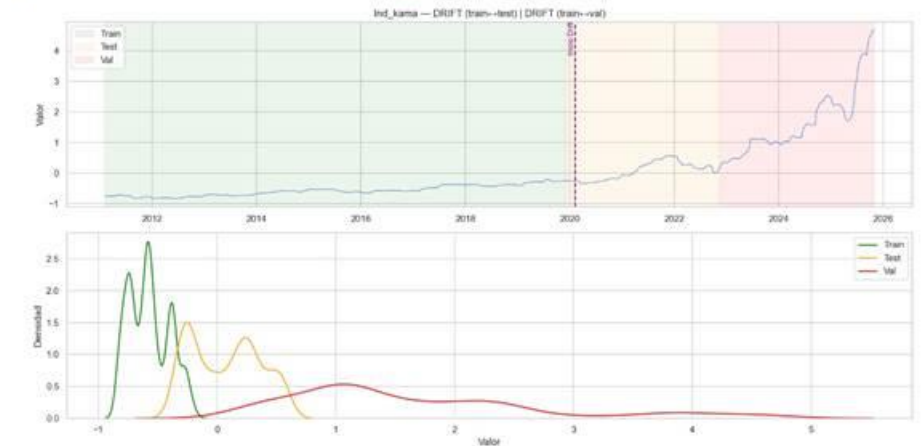


Figure 1

Figure 1


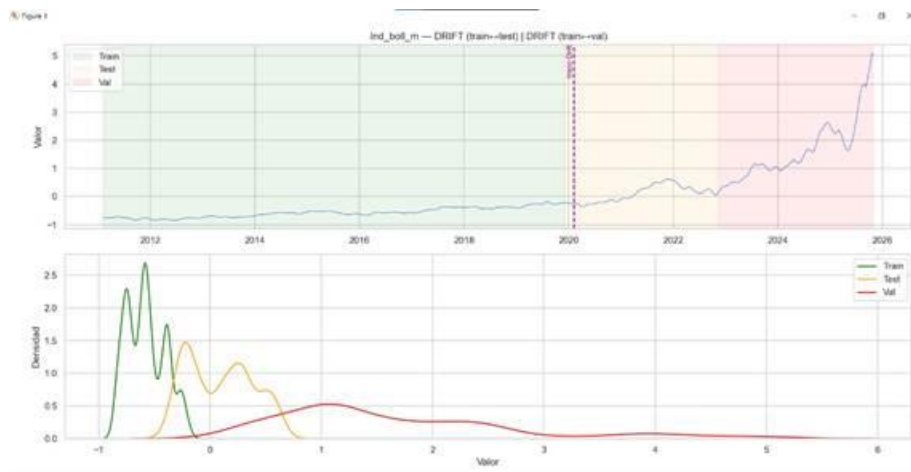



Figure 1



Como nos podemos fijar en cada una de las tablas es que se muestra que inicia en un punto muy bajo en 2012 pero una vez llega a 2020 es donde inicia el drift esto porque al ser un salto algo grande es que los datos empiezan a cambiar bastante debido a cómo es que se fueron creciendo los precios de Oracle y en el área de validación es que vemos que ya no solo se hace más volátil, sino que también tiene un crecimiento explosivo en la media.

Por último las señales de compraventa coseno y seno fueron las que no mostraron ningún tipo de deriva porque estas dependían de todas las demás variables y sus bandejas de valor nunca superaban el 0 o 1 por lo cual durante todo el tiempo se generaban señales para ver si es que superaban el 65% para ver si comprabas o no.



Comparación de modelos

Modelos CNN

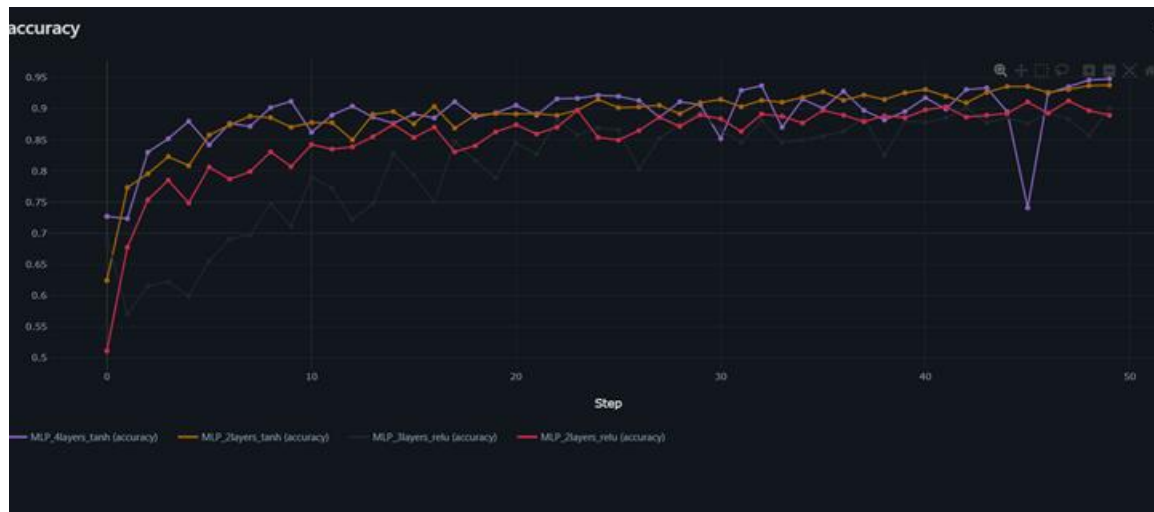


Vemos que tiene un accuracy alto vemos que en general llega entre el 0.93 el modelo de CNN_2_conv_tanh por lo cual creemos que predice bien los datos, pero al recordar que la mayoría de los datos son 0 y también queremos general señales de compra y venta puede que tener un accuracy muy alto perjudique al trading ya que casi no se compraría o puede que se compre en lugares que no deba debido al class balancing que se hizo.



La misma historia con el f1 vemos que, aunque el mejor es el mismo modelo que la vez pasada tiene un F1 bajo por lo cual nos puede indicar dos cosas que hay un desbalanceo que se sabe que hay y que todavía es muy ruidoso la señal de trading por lo cual se tendrá que trabajar los modelos en general debido a los grandes cambios que hubo en el tiempo de la acción.

Modelos MLP



En general se puede observar que también tuvo un buen accuracy al medir los valores, pero igual que con el CNN se hará con ambos en modelo con mayor y menor accuracy con la meta de verificar si es que esta lleva a mejores resultados.



Y de nuevo igual que el modelo CNN vemos que se tiene un F1 score bajo de apenas el 0.4 o sea que nos muestra los mismos resultados que sabemos que hay una alta disparidad de datos a pesar del balanceo.

Y por último se va a comparar los modelos con mayor y menor accuracy y contra los datos reales con las señales de trading previamente calculadas.

Scenario	Final Portfolio	Total Return	Sharpe Ratio	Sortino Ratio	Calmar Ratio	Max Drawdown	Annualized Volatility	Total Trades	Win Rate
Datos Reales	71421.40904	-0.28578591	-2.11447841	-0.979941966	-1	-0.28578591	0.0248153	69	0.608695652
MLP - Mayor Accuracy	51711.03124	-0.482889688	-3.138846396	-2.500199327	-0.993650443	-0.485482718	0.084151166	121	0.644628099
CNN - Mayor Accuracy	15437.54385	-0.845624561	-5.420784355	-4.446761158	-0.99891273	-0.846398671	0.123660358	202	0.574257426
MLP - Menor Accuracy	15846.17711	-0.841538229	-5.073256079	-3.994005268	-0.998878563	-0.842332829	0.130193395	233	0.592274678
CNN - Menor Accuracy	13704.83229	-0.862951677	-5.378044761	-4.943069685	-0.999054034	-0.863638901	0.131920508	302	0.569536424

Podemos ver para iniciar que el que mejor resultado da son los datos reales, aunque en todos se pierde, también podemos ver que en general mientras más trading haya es que más se pierde en el portafolio, pero esto no necesariamente es culpa de ningún modelo puede que haya sido que al programar los indicadores se fueron muy permisivos o no se usaron de la manera óptima para generar las señales de compraventa, aparte podemos ver que en general mientras peor accuracy tiene más trading. Otra cosa clara para ver que en general una mayor accuracy si puede llevar a mejores modelos vemos que se ganaron más del 50% de las veces que se generaban trading, pero si vemos en general se llegaron a perder mucho porque compraron en momentos donde el mercado no estaba para comprar.

12. Conclusiones

En conclusión una mayor accuracy te va dar un modelo más seguro ya que seguirá las señales de compra venta de indicadores financieros, en todos los casos hagan compras en momentos oportunos que no capto el modelo, también es importante añadir la importancia de comparar estos dos modelos ya que vemos que en general uno se comporta de manera más agresiva siendo el CNN, y vemos que en todos los casos perdemos esto igual debido a que los índices pudieron haber generado señales en mejores momentos o por debido al entrenamiento se ajustó con datos de épocas en las que Oracle era todavía una empresa chica a crecer de golpe en el periodo de validación lleve a que el modelo no esté bien preparado para ver cierres tan altos en los precios.

En general hay bastantes áreas de mejoras un Deep learning más profundo podría iniciar porque el modelo CNN se llegó hasta 3 capas y en el MLP se llegó a 4 y aunque no siempre más es mejor podría haber ayudado debido a la gran diferencia que se encontraban los datos, los índices financieros también pudieron haber sido mejorados debido a la importancia que estos tienen al entrenamiento y el modelo en general. Por último, a lo mejor otro modelo de Deep learning o una combinación de estos puede que lleve a mejores resultados a solo probar dos puede que los datos no estén del todo mal, sino que otro modelo se pueda ajustar mejor.

Referencias

- Investopedia. (2025). Rate of Change (ROC). Recuperado de <https://www.investopedia.com/terms/r/rateofchange.asp>
- Banco Santander. (2025). RSI o índice de fuerza relativa. Recuperado de <https://www.bancosantander.es/glosario/rsi-o-indice-de-fuerza-relativa>
- IG Markets. (2025). Guía del inversor para utilizar el indicador Williams %R. Recuperado de <https://www.ig.com/es/estrategias-de-trading/guia-del-inversor-para-utilizar-el-indicador-williams--r-200814>
- Estrategias de Inversión. (2025). TRIX - Triple Exponential Average. Recuperado de <https://www.estrategiasdeinversion.com/herramientas/diccionario/analisis-tecnico/trix-t-393>
- TradingView. (2025). Documentación de indicadores técnicos. Recuperado de <https://es.tradingview.com/support/solutions/43000501974>
- Corporate Finance Institute. (2025). Volatility Ratio. Recuperado de <https://corporatefinanceinstitute.com/resources/career-map/sell-side/capital-markets/volatility-ratio>
- IG Latam. (2025). Definición de indicador OBV. Recuperado de <https://www.ig.com/latam/glosario-trading/definicion-de-indicador-obv>
- Investopedia. (2025). Awesome Oscillator. Recuperado de <https://www.investopedia.com/articles/trading/03/031203.asp>
- IG Latam. (2025). Definición de VWAP. Recuperado de <https://www.ig.com/latam/glosario-trading/definicion-de-vwap>
- Investopedia. (2025). Chande Momentum Oscillator. Recuperado de <https://www.investopedia.com/terms/c/chandemomentumoscillator.asp>
- DataScientest. (2025). Convolutional Neural Networks. Recuperado de <https://datascientest.com/es/convolutional-neural-network-es>
- GAMCO. (2025). Perceptrón Multicapa (MLP). Recuperado de <https://gamco.es/glosario/perceptron-multicapa-mlp>